SPRAWOZDANIE Z PROJEKTU

Temat: System kontroli dostępu oparty na biometrii głosowej — aplikacja autoryzująca użytkownika na podstawie unikalnych cech głosu

Przedmiot: Bezpieczeństwo systemów komputerowych

1. Wprowadzenie i cel projektu

Celem projektu było zaprojektowanie i implementacja działającego **systemu kontroli dostępu wykorzystującego biometrię głosową**. System uwierzytelnia użytkownika na podstawie unikalnych cech jego głosu (barwy, charakterystyki traktu głosowego), przyznając dostęp właścicielowi i odrzucając inne osoby — nawet o podobnym głosie, np. członków rodziny.

Projekt obejmuje również szereg mechanizmów istotnych z punktu widzenia bezpieczeństwa systemów komputerowych: zapasowe uwierzytelnianie kodem PIN (przechowywanym jako hash), ochronę przed atakami brute-force (blokada czasowa), test żywotności (anti-spoofing), wyzwanie losową frazą (challenge-response) oraz pełny audyt zdarzeń.

2. Podstawy teoretyczne

2.1. Biometria głosowa

Biometria głosowa należy do biometrii **behawioralno-fizjologicznej** — głos zależy zarówno od budowy anatomicznej (krtań, trakt głosowy), jak i sposobu mówienia. W projekcie zastosowano klasyczne podejście **GMM-UBM** (Gaussian Mixture Model – Universal Background Model) stosowane w systemach rozpoznawania mówcy.

2.2. Ekstrakcja cech — MFCC

Z nagrania wyznaczane jest **20 współczynników melowo-cepstralnych (MFCC)** w kolejnych ramkach czasowych. Współczynniki te opisują barwę głosu w sposób zbliżony do percepcji ludzkiego ucha. Aby zapewnić powtarzalność niezależnie od warunków:

- **przycinana jest cisza** (pauzy nie zaburzają wyniku),
- stosowana jest **normalizacja amplitudy** (głośność przestaje mieć znaczenie),
- stosowane jest **CMVN** (Cepstral Mean-Variance Normalization), które usuwa wpływ mikrofonu i kanału transmisyjnego.

2.3. Model decyzyjny

Tworzone są dwa modele mieszanin Gaussa:

- **model użytkownika** — uczony na próbkach właściciela,
- **model tła (UBM)** — uczony na głosach wielu innych osób.

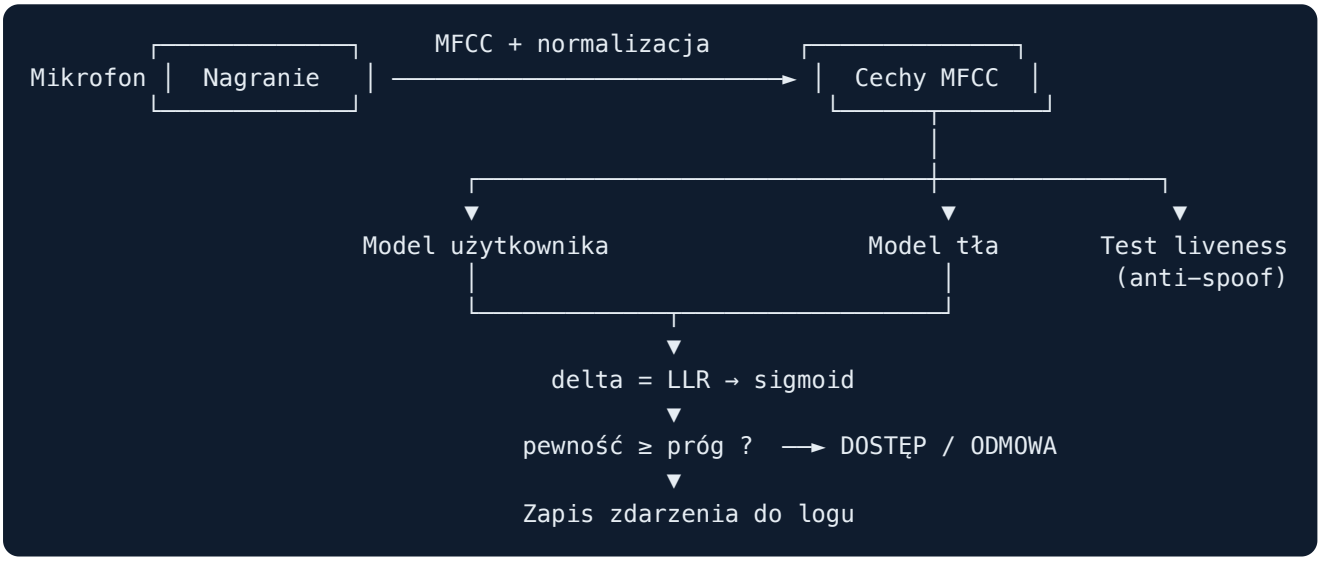
Decyzja zapada na podstawie logarytmicznego ilorazu wiarygodności:

```
delta   = log P(nagranie | model_użytkownika) − log P(nagranie | model_tła)
pewność = sigmoid(delta) × 100%
```

Dostęp jest przyznawany, gdy `pewność ≥ próg` (przyjęto **70%**).

---

3. Architektura systemu



Główne moduły:

- `app.py` — interfejs graficzny (logowanie + panel),
- `security.py` — ekstrakcja cech, liveness, PIN, blokada, audyt, historia,
- `train_model.py` — trening modeli GMM,
- `enroll.py`, `record_impostor.py`, `download_polish.py` — przygotowanie danych,
- `evaluate.py` — ewaluacja jakości (FAR/FRR/EER).

---

4. Mechanizmy bezpieczeństwa

Mechanizm	Opis
Uwierzytelnianie biometryczne	rozpoznawanie mówcy metodą GMM-UBM

Mechanizm	Opis
Druga metoda — PIN	przechowywany jako **hash PBKDF2-HMAC-SHA256 (100 000 iteracji) z losową solą**, nigdy jawnie
Ochrona przed atakami czasowymi	porównanie hashy przez `secrets.compare_digest`
Licznik prób + blokada czasowa	po 3 nieudanych próbach blokada 30 s (ochrona przed brute-force)
Test anty-spoofingowy (liveness)	wykrywa ciszę, odtworzone nagranie i syntetyczny ton na podstawie energii, dynamiki, tempa mowy i widma
Challenge-response	losowa fraza do wypowiedzenia przy każdym logowaniu (utrudnia atak replay)
Audyt zdarzeń	każde zdarzenie zapisywane z datą, godziną, wynikiem i pewnością

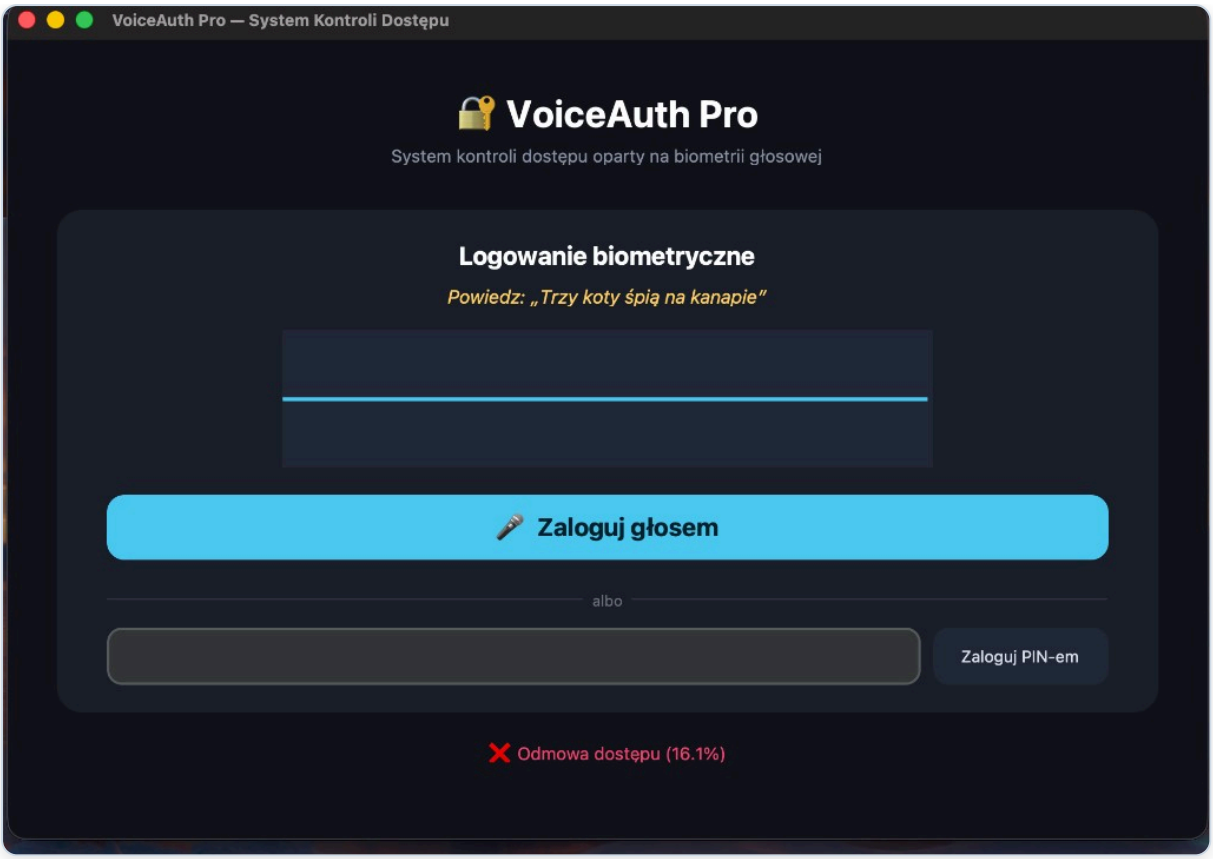
Przechowywanie danych uwierzytelniających: PIN tylko jako hash z solą; głos jako statystyczny model GMM, z którego nie można odtworzyć nagrania. Żadne dane uwierzytelniające nie są przechowywane w postaci jawnej.

---

5. Działanie aplikacji (zrzuty ekranu)

5.1. Ekran logowania

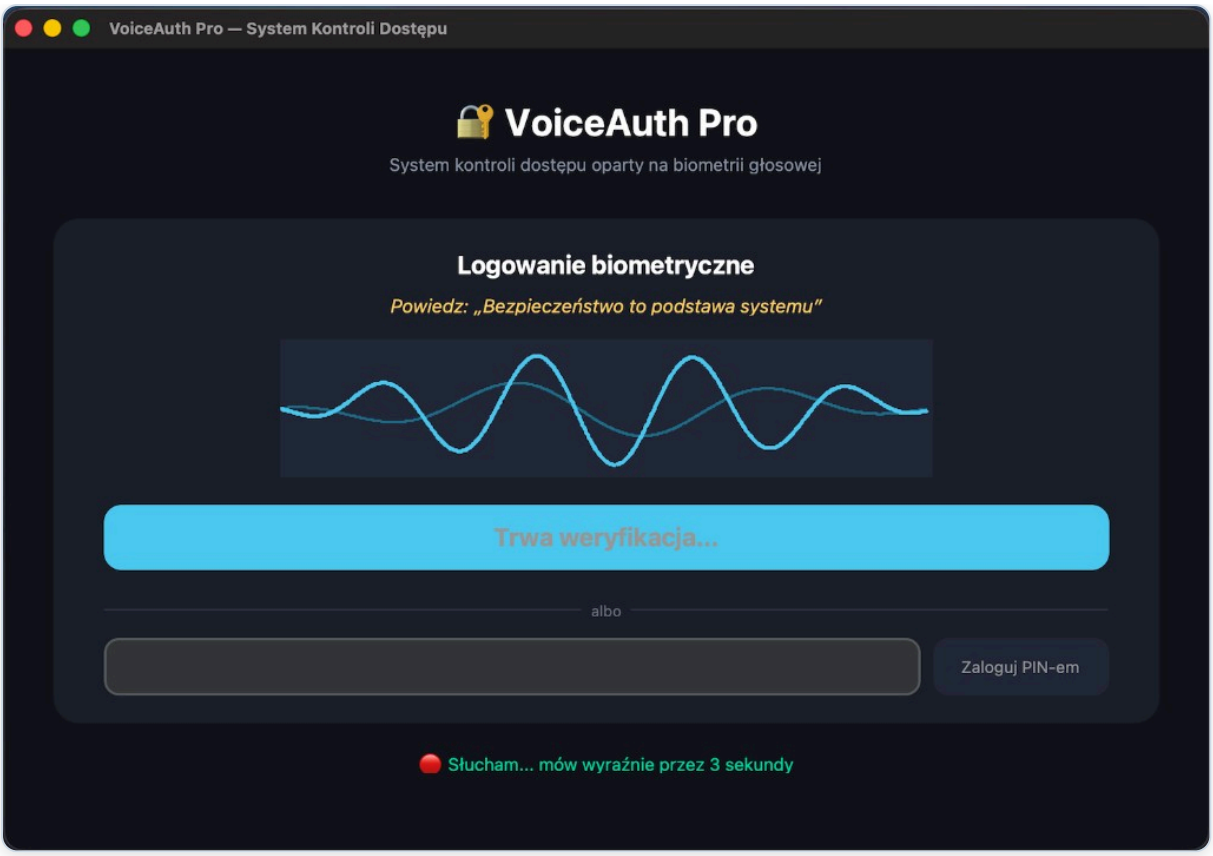
Użytkownik widzi losową frazę do wypowiedzenia (challenge-response). Może zalogować się **głosem** lub zapasowo **kodem PIN**. Poniżej widoczna odmowa dostępu dla nieuprawnionej próby (wynik 16.1%, poniżej progu).



Ekran logowania

5.2. Nagrywanie i weryfikacja głosu

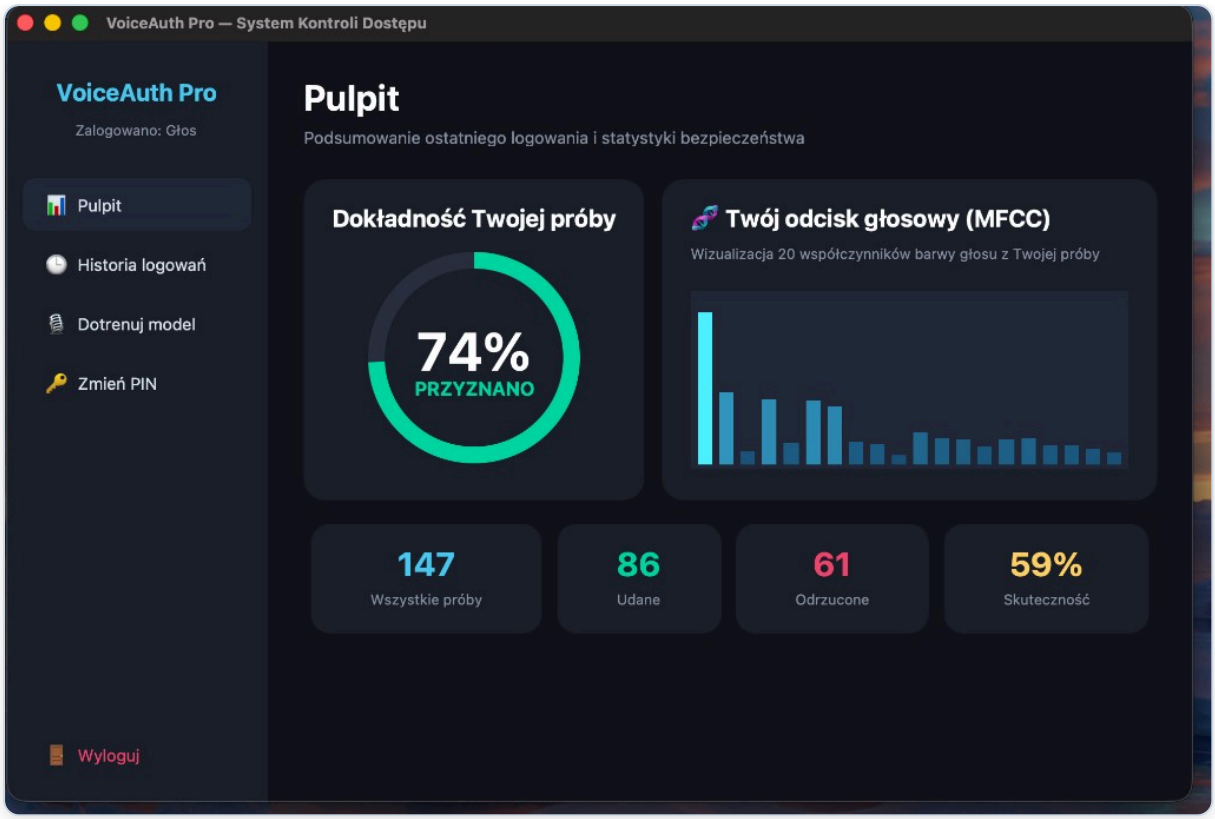
W trakcie nagrywania wyświetlana jest animowana fala dźwiękowa oraz komunikat o trwającej analizie biometrycznej.



Nagrywanie głosu

5.3. Pulpit — dokładność próby i odcisk głosowy

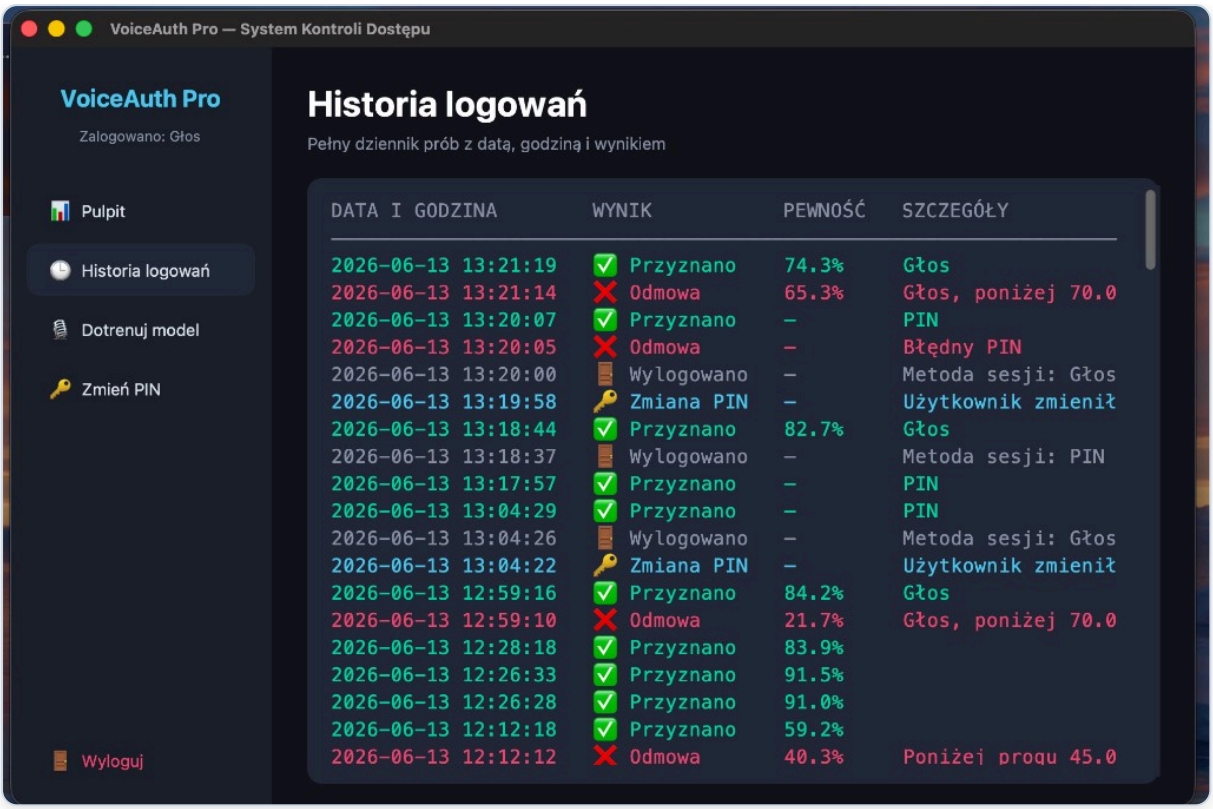
Po zalogowaniu dostępny jest pulpit z **dokładnością ostatniej próby** (wskaźnik kołowy — tu 74%, dostęp przyznany), **odciskiem głosowym (MFCC)** oraz statystykami bezpieczeństwa (liczba prób, udane, odrzucone, skuteczność).



Pulpit

5.4. Historia logowań

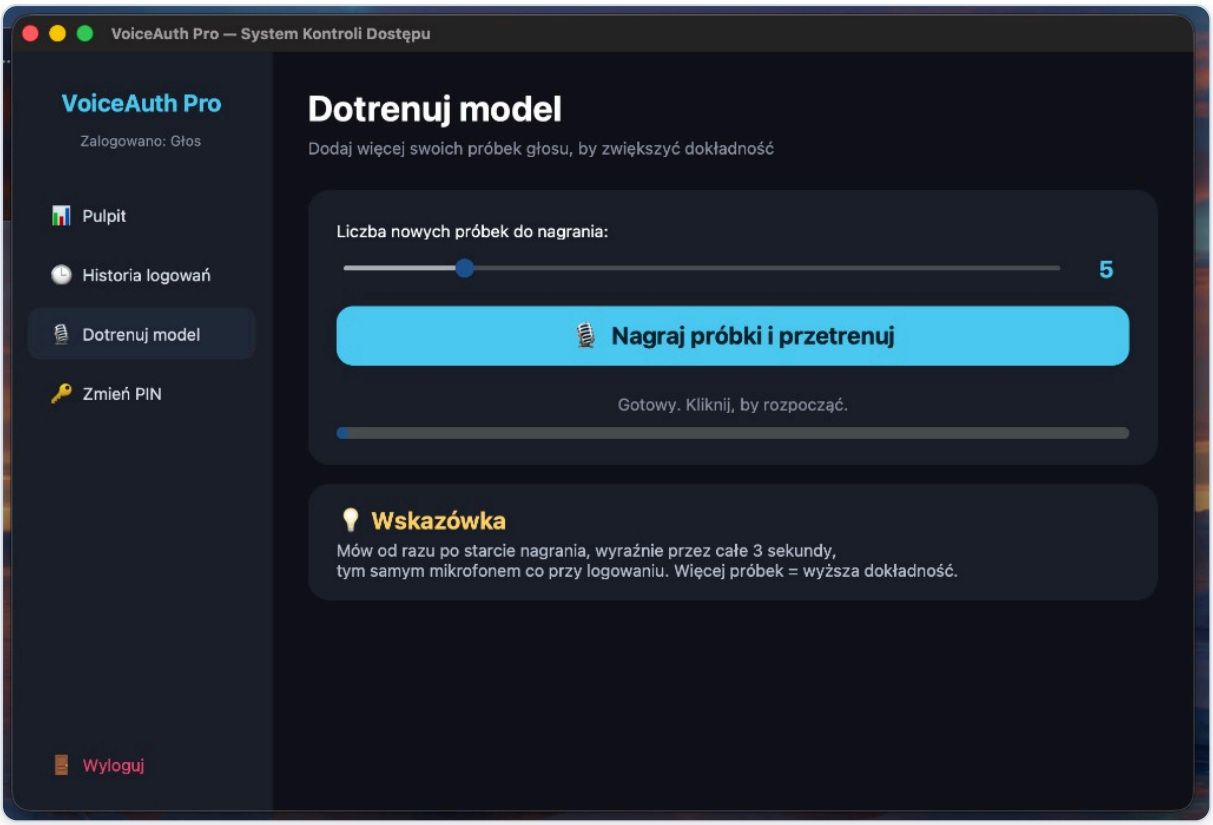
Pełny dziennik zdarzeń z datą, godziną, wynikiem, pewnością i szczegółami (metoda logowania, powód odmowy itp.). Widać tu m.in. udane logowania głosem, odmowy poniżej progu, logowania PIN-em, zmiany PIN i wylogowania.



Historia logowań

5.5. Dotrenowanie modelu

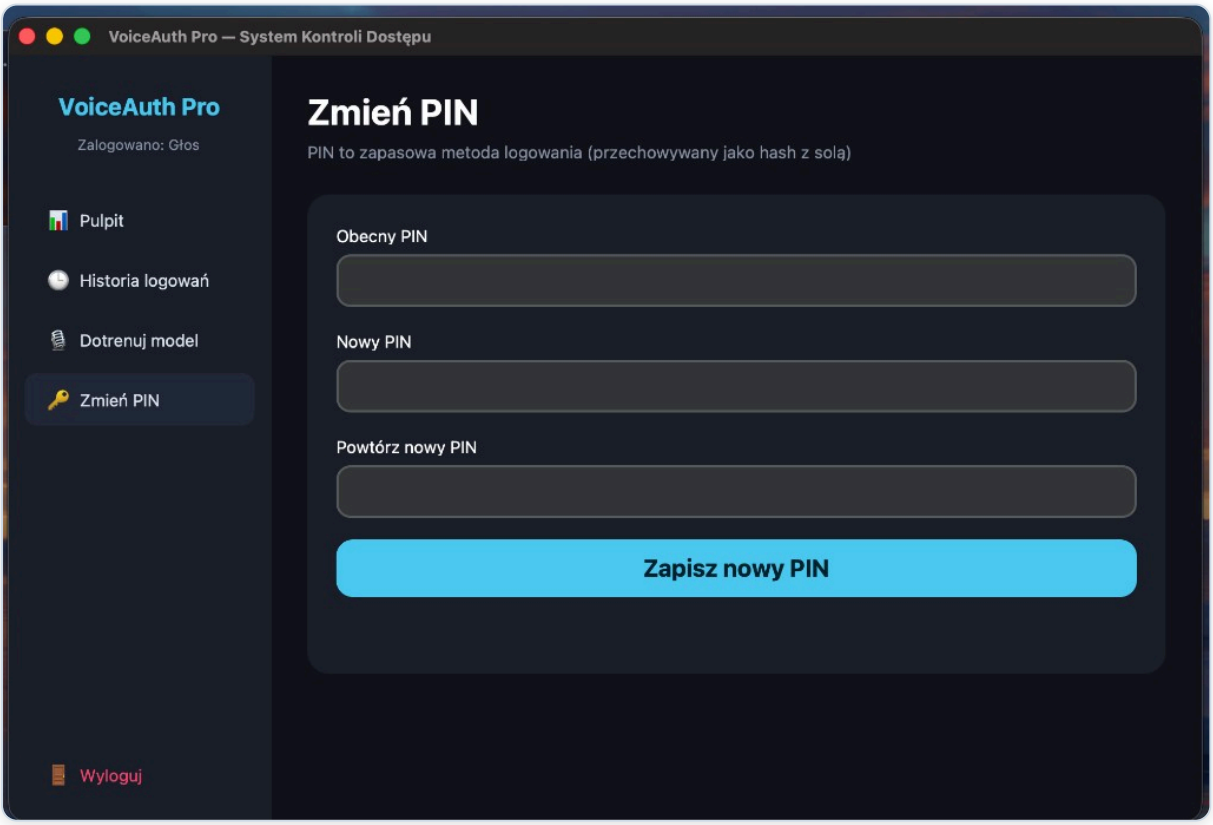
Użytkownik może dodać własne próbki głosu bezpośrednio z aplikacji (suwak wyboru liczby próbek) i automatycznie przetrenować model, co zwiększa dokładność.



Dotrenuj model

5.6. Zmiana PIN

Zmiana PIN-u wymaga podania obecnego kodu i jest zapisywana jako hash z solą.



Zmiana PIN

6. Testy i wyniki

6.1. Rozróżnianie użytkownika od innych osób (test praktyczny)

W testach z udziałem rodziny:

- **właściciel** uzyskiwał wyniki rzędu **80–96%**,
- **inni domownicy** (mama, tata) uzyskiwali wyniki **poniżej progu**,

co potwierdza skuteczne rozróżnianie nawet spokrewnionych, podobnych głosów po dobraniu progu i wzbogaceniu modelu tła o polskie głosy.

6.2. Ewaluacja ilościowa (FAR / FRR / EER)

Skrypt `evaluate.py` wyznaczył standardowe metryki jakości systemów biometrycznych (79 nagrań właściciela, 300 nagrań intruzów):

Metryka	Wynik
Średnia pewność — właściciel	95.2%
Średnia pewność — intruzi	3.0%
EER (Equal Error Rate)	**0.00%** (przy progu 9.7%)
FAR przy progu 70% (intruzi wpuszczeni)	0.00%
FRR przy progu 70% (właściciel odrzucony)	1.27%

- **FAR** (False Acceptance Rate) — odsetek intruzów błędnie wpuszczonych,
- **FRR** (False Rejection Rate) — odsetek właściciela błędnie odrzuconego,
- **EER** — punkt równowagi FAR = FRR (im niższy, tym lepszy system).

7. Wnioski

1. System poprawnie realizuje uwierzytelnianie biometryczne — odróżnia właściciela od innych mówców z wysoką skutecznością (EER 0% na zbiorze testowym).
2. Najważniejszą lekcją z zakresu bezpieczeństwa jest to, że **wynik EER zależy od reprezentatywności danych**. Idealny wynik dotyczył „łatwych" intruzów z internetu (inny język, inny mikrofon). W praktyce trudniejszym przypadkiem jest osoba spokrewniona przy tym samym mikrofonie — cechy głosu są częściowo dziedziczne, więc FAR rośnie. Ograniczono to, wzbogacając model tła o **polskie głosy** oraz umożliwiając dodanie lokalnych próbek negatywnych.

3. Dobór progu decyzyjnego to bezpośredni kompromis między **wygodą** (niski FRR) a **bezpieczeństwem** (niski FAR).
4. Zastosowane mechanizmy (hashowanie PIN, blokada czasowa, liveness, challenge-response, audyt) pokazują warstwowe podejście do bezpieczeństwa, w którym biometria jest tylko jednym z elementów.

Możliwy dalszy rozwój

- adaptacja MAP modelu użytkownika z UBM (lepsze działanie przy małej liczbie próbek),
- cechy delta/delta-delta MFCC,
- zaawansowana detekcja spoofingu (anti-replay, wykrywanie syntezy mowy),
- obsługa wielu użytkowników i ról.

---

8. Instrukcja uruchomienia

```
# (opcjonalnie) pobranie polskich głosów tła
pip install datasets soundfile
python download_polish.py

# trening modeli
python train_model.py

# uruchomienie aplikacji
python app.py
```

Domyślny PIN: **1234** (do zmiany w panelu po zalogowaniu). Wymagane biblioteki: `librosa`, `numpy`, `scipy`, `scikit-learn`, `sounddevice`, `joblib`, `customtkinter`, `soundfile`.